

Proj57 初赛演示: ACT 模型在 RK3588 上的 RKNN 推理闭环

面向具身智能的国产操作系统 ACT 模型适配与实时推理优化

李捷铭 (队长, 清华大学) 朱屹帆 杨若朝

OS 功能挑战赛道 Proj57

2026 年 6 月 30 日

核心结论: ONNX 到 RKNN 转换已完成, Orange Pi RK3588 板端 C++ RKNN runtime 已跑出两个代表样例。

本次展示要证明什么

赛题目标

使用统一 ACT 模型，在 StarryOS/QEMU 与嵌入式平台上完成推理部署，输出动作预测结果。

- 任务三：QEMU/StarryOS CPU 路线，是初赛保底链路。
- 任务二：Orange Pi RK3588/NPU 路线，是当前硬件适配主线。
- 本次展示重点：证明任务二的最小推理闭环已经真实跑通，而不是只停留在方案设计。

我们实际完成的链路

模型链路

- PyTorch checkpoint: `model.pt`
- 导出 ONNX: `act.onnx`
- 转换 RKNN: `act_rk3588_fp.rknn`
- 板端 C++ 调用: `librknnrt.so`

动作判断

- 输入: 图像、机器人状态、latent 向量
- 输出: 未来 8 步 action
- 第一维: `left_vel`
- 第二维: `right_vel`
- 判断: 左轮速度小于右轮速度时为 LEFT

板端证据 1: Orange Pi 5 Plus 实物与系统



```
Orange Pi board information

$ hostname
ubuntu

$ cat /proc/device-tree/model
Orange Pi 5 Plus

$ uname -a
Linux ubuntu 5.10.0-1012-rockchip #12-Ubuntu SMP Wed Aug 14 22:22:22 UTC 2024 aarch64
aarch64 aarch64 GNU/Linux

$ grep PRETTY_NAME /etc/os-release
PRETTY_NAME="Ubuntu 22.04.5 LTS"

$ free -h
```

	total	used	free	shared	buff/cache	available
Mem:	3.8Gi	198Mi	2.4Gi	2.0Mi	1.3Gi	3.6Gi
Swap:	0B	0B	0B			

已确认板型为 Orange Pi 5 Plus, 系统为 Ubuntu 22.04.5 LTS, 架构为 aarch64, 内存约 3.8 GiB。

板端证据 2: NPU 节点与 RKNN Runtime

● ● ● RKNN runtime and NPU nodes

```
$ ls -l /dev/dri/by-path | grep -i npu
lrwxrwxrwx 1 root root 8 Jun 24 12:44 platform-fdab0000.npu-card -> ../card1
lrwxrwxrwx 1 root root 13 Jun 24 12:44 platform-fdab0000.npu-render -> ../renderD129

$ ls -l /usr/lib/librknnrt.so
-rw-r--r-- 1 root root 5241256 Jun 24 06:19 /usr/lib/librknnrt.so

$ ls /usr/local/include/rknn
rknn_api.h
rknn_matmul_api.h

$ dmesg | grep -i rknpu | tail -n 6
[34530.470582] RKNPU: invalid rknpu task number!
[34530.470614] RKNPU: invalid rknpu task number!
[34530.470636] RKNPU: invalid rknpu task number!
[34530.470867] RKNPU: invalid rknpu task number!
[34530.471180] RKNPU: invalid rknpu task number!
[34530.471593] RKNPU: invalid rknpu task number!
```

已确认

NPU DRM 节点、/usr/lib/librknnrt.so 和 RKNN 头文件存在。图中的 RKNPU warning 是后续需要处理的 runtime/driver 版本问题。

ONNX 基线：先证明模型本身输出正确

已复现的 ONNX Runtime 结果

- frame_000000.jpg -> LEFT, 符合预期。
- frame_000227.jpg -> RIGHT, 符合预期。
- Windows 本机 ONNX Runtime CPU: 两个样例平均约 25.91 到 26.78 ms。
- QEMU/StarryOS 既有报告结果: 约 18.4 到 18.7 s, 峰值内存约 454 MB。

为什么先做 ONNX 基线

RKNN 输出不要求 bit-exact, 但方向必须和基线一致。ONNX 基线是 RKNN 板端结果的正确性对照。

RKNN 转换结果

转换环境

- WSL Ubuntu 24.04 / x86_64
- rknn-toolkit2 2.3.2
- torch 2.4.0+cpu
- onnx 1.16.2

模型大小

文件	大小
model.pt	202,962,639 B
act.onnx	202,633,726 B
act_rk3588_fp.rknn	101,709,294 B

转换脚本: `tools/convert_act_rknn.py`。板端运行程序: `tools/rknn_runtime_infer.cpp`。

RKNN 板端运行结果：两个代表样例

   RKNN result: frame_000000

```
$ cd /home/ubuntu/proj57_rknn_run && grep key lines runtime_log_frame000_nhwc.txt
api_version=1.5.2 (c6b7b351a@2023-08-23T15:28:22)
drv_version=0.9.6
rknn_perf_run_us=34968
wall_ms=34.998
first_step_denorm_left=-0.001526 right=0.007373 grip=0.000000 direction=LEFT
```

   RKNN result: frame_000227

```
$ cd /home/ubuntu/proj57_rknn_run && grep key lines runtime_log_frame227_nhwc.txt
api_version=1.5.2 (c6b7b351a@2023-08-23T15:28:22)
drv_version=0.9.6
rknn_perf_run_us=25340
wall_ms=25.364
first_step_denorm_left=0.006128 right=-0.000488 grip=0.000000 direction=RIGHT
```

结论: frame_000000 -> LEFT, frame_000227 -> RIGHT, 方向与 ONNX 基线一致。

性能与资源数据

平台	后端	状态	模型大小	推理耗时
QEMU/StarryOS	ONNX CPU	已有报告	193.2 MB	18.4–18.7 s
Windows 本机	ONNX CPU	已复现	193.25 MB	25.91–26.78 ms
Orange Pi RK3588	RKNN/NPU	已跑通	97.0 MiB	25.34–35.00 ms

- RKNN runtime 返回的 `rknn_perf_run_us` 分别为 34968 和 25340。
- 两个样例的 LEFT/RIGHT 方向与 ONNX 基线一致。

任务二现在到底完成到什么程度

可以确认完成

- 已完成 ONNX 模型导出
- 已完成 RKNN 模型转换
- 已完成 RK3588 板端 C++ runtime
- 已完成 两个代表样例方向正确
- 已完成 记录模型大小和推理耗时

仍需完善

- 待完善 当前输入是预处理后的 tensor bin
- 待完善 还不是直接 JPEG 到推理输出
- 待完善 runtime 版本警告仍存在
- 待完善 样例数量还需要扩展

稳妥表述：任务二 RK3588 平台 ACT 推理最小闭环已经跑通，后续进入工程化和稳定性优化。

本次新增工程产物

- 修复 ONNX 导出流程：避免下载 torchvision 预训练权重，自动创建 build/ 目录。
- 新增 RKNN 转换脚本：tools/convert_act_rknn.py。
- 新增 RKNN 板端 C++ runtime：tools/rknn_runtime_infer.cpp。
- 采集板端证据：系统信息、NPU 节点、RKNN runtime、运行日志。
- 整理初审材料：技术文档、性能表、演示脚本、PDF 和本 PPT。

板端同步目录：/home/ubuntu/proj57_initial_review。

下一步计划

- ❶ 对齐 RKNN Toolkit2 与板端 runtime 版本, 消除 invalid run task counter 警告。
- ❷ 把 C++ runtime 扩展为完整命令行工具, 支持 JPEG 读取、resize、normalize、推理和后处理。
- ❸ 增加更多 LEFT/RIGHT 样例回归, 记录精度漂移、耗时波动和内存占用。
- ❹ 面向任务一 SG2002 的 256 MB 内存约束, 继续探索模型裁剪、量化和算子拆分。

总结

结论

我们已经完成从 `model.pt` 到 `act.onnx`, 再到 `act_rk3588_fp.rknn`, 最后在 Orange Pi RK3588 上通过 C++ RKNN runtime 输出动作方向的最小闭环。

- 任务三结果提供保底正确性和对照。
- 任务二已经有真实板端运行日志和性能数据。
- 当前主要风险已经明确, 后续工作路径清晰。